

Analisis Siklus Sel dengan Metode Hybrid *Deep Learning* dan *Biological Validation*

Wisa Ahmaduta Dinutama Stanislaus Ardy Bramantyo
18122003@std.stei.itb.ac.id 18223057@std.stei.itb.ac.id
Institut Teknologi Bandung Institut Teknologi Bandung

Sendi Putra Alicia Ghazy Achmed M. Urbayani
18223063@std.stei.itb.ac.id 18223093@std.stei.itb.ac.id
Institut Teknologi Bandung Institut Teknologi Bandung

Abstract—Siklus sel merupakan proses fundamental yang mengatur pembelahan sel, dan disregulasinya merupakan ciri khas kanker. Penelitian ini mengembangkan sistem analisis siklus sel tiga lapis yang mengintegrasikan *deep learning* dengan validasi biologis. Layer 1 menggunakan Convolutional Neural Network (ResNet-18) untuk klasifikasi fase dari citra mikroskopi fluoresensi dataset BBBC048 (Broad Institute). Layer 2 menerapkan model Ordinary Differential Equation (ODE) Tyson-Novak untuk memodelkan dinamika Cyclin B/CDK1/APC dan menurunkan matriks transisi untuk Hidden Markov Model (HMM) yang mengoreksi prediksi temporal. Layer 3 mengimplementasikan detektor anomali berbasis aturan biologi checkpoint (G1/S restriction point, G2/M DNA damage, spindle assembly). Hasil eksperimen menunjukkan koreksi HMM meningkatkan akurasi sekuensial sebesar $\sim 15\%$ dibandingkan CNN saja, dan sistem mampu mendeteksi anomali checkpoint yang relevan secara klinis. Sistem dilengkapi aplikasi web interaktif untuk inferensi real-time dan visualisasi pipeline.

Index Terms—siklus sel, convolutional neural network, ordinary differential equation, hidden Markov model, checkpoint, Grad-CAM, analisis populasi

I. PENDAHULUAN

A. Latar Belakang Biologi Siklus Sel

Siklus sel adalah rangkaian peristiwa teratur yang mengarah pada duplikasi konten seluler dan pembelahan menjadi dua sel anak [1]. Proses ini terdiri dari dua fase utama: *interphase* (G1, S, G2) di mana sel tumbuh dan mereplikasi DNA, serta *mitosis* (Prophase, Metaphase, Anaphase, Telophase) di mana kromosom dipisahkan dan sel membelah secara fisik.

Durasi setiap fase bervariasi namun mengikuti pola yang konsisten pada tipe sel tertentu. Untuk sel mamalia tipikal, G1 berlangsung 10–12 jam, S fase 6–8 jam, G2 sekitar 4 jam, sedangkan seluruh mitosis hanya memakan waktu ~ 1 jam [9]. Regulasi temporal ini dikontrol oleh osilasi kompleks Cyclin-Dependent Kinase (CDK) yang berikatan dengan protein Cyclin spesifik pada setiap fase [2].

Tiga checkpoint utama memastikan integritas proses:

- **G1/S Restriction Point:** Dikontrol oleh jalur Rb/E2F dan p53/p21. Sel harus mencapai ukuran cukup dan menerima sinyal mitogenik sebelum berkomitmen pada replikasi DNA. Bypass checkpoint ini (misalnya melalui mutasi Rb atau overekspresi Cyclin D) merupakan langkah awal transformasi onkogenik.
- **G2/M DNA Damage Checkpoint:** Jalur ATM/ATR $\rightarrow$ Chk1/Chk2 $\rightarrow$ Wee1 memverifikasi bahwa replikasi DNA

telah selesai tanpa kerusakan. Kegagalan checkpoint ini menyebabkan sel memasuki mitosis dengan DNA rusak, menghasilkan instabilitas genomik.

- **Spindle Assembly Checkpoint (SAC):** Protein Mad2 dan BubR1 memastikan semua kinetokore terikat pada mikrotubulus spindle sebelum onset anafase. Override SAC menyebabkan missegregasi kromosom dan aneuploidi — fenotip *Chromosomal Instability* (CIN).

Disregulasi checkpoint merupakan salah satu dari sepuluh *hallmarks of cancer* [3], menjadikan deteksi otomatis anomali checkpoint bernilai klinis tinggi untuk skrining dan diagnosis.

B. Metode Komputasi Terkait dan Tinjauan Pustaka

Klasifikasi otomatis fase siklus sel dari citra mikroskopi telah berkembang dari metode berbasis fitur handcrafted (tekstur, morfologi) ke pendekatan *deep learning*. Eulenberg et al. [4] mendemonstrasikan bahwa CNN dapat merekonstruksi progresi siklus sel dari citra fluoresensi single-cell pada dataset BBBC048, mencapai akurasi tinggi. Namun, pendekatan ini murni *data-driven* — tidak memanfaatkan pengetahuan biologis tentang dinamika molekuler yang mendasari transisi fase.

Di sisi lain, model matematika siklus sel berbasis ODE telah dikembangkan secara ekstensif. Model Tyson-Novak [2] menangkap esensi osilator Cyclin B/CDK1/APC melalui sistem persamaan diferensial dengan *ultrasensitive switches* (fungsi Goldbeter-Koshland). Model ini mampu mereproduksi perilaku bistabil dan osilasi yang menjadi dasar progresi siklus sel.

Hidden Markov Model (HMM) telah menjadi *workhorse* dalam bioinformatika untuk analisis sekuens [5], namun penerapannya untuk koreksi temporal pada klasifikasi citra siklus sel — khususnya dengan matriks transisi yang diturunkan dari model biofisika — belum dieksplorasi.

C. Rumusan Masalah

Penelitian ini menjawab tiga pertanyaan:

- 1) Bagaimana mengintegrasikan CNN image classifier dengan constraint biologis dari dinamika Cyclin-CDK untuk menghasilkan prediksi yang konsisten secara temporal?
- 2) Seberapa besar peningkatan akurasi yang diperoleh dari koreksi HMM dengan matriks transisi yang diturunkan dari model ODE biologis?




Fig. 1. Arsitektur tiga lapis sistem analisis siklus sel. Layer 1 (hijau) melakukan klasifikasi citra. Layer 2 (biru) memberikan validasi temporal dari model biosfisika. Layer 3 (merah) mendeteksi anomali checkpoint.

- 3) Bagaimana mendeteksi anomali checkpoint secara otomatis menggunakan aturan yang diturunkan langsung dari biologi sel, dan apa signifikansi klinisnya?

D. Kontribusi

Kontribusi utama penelitian ini:

- 1) Arsitektur tiga lapis yang menunjukkan aliran bidi-reksional antara computer science dan biologi: CNN mengekstrak informasi dari citra (CS→Bio), sementara ODE dan checkpoint rules memberikan constraint biologis kembali ke pipeline komputasi (Bio→CS).
- 2) Pendekatan novel untuk menurunkan matriks transisi HMM dari solusi numerik ODE Cyclin-CDK, bukan dari data training — menjadikan model *biologically-informed* secara eksplisit.
- 3) Detektor anomali checkpoint yang mampu membedakan artefak klasifikasi dari anomali biologis genuine, dengan interpretasi klinis otomatis.
- 4) Visualisasi Grad-CAM yang memvalidasi bahwa CNN memperhatikan fitur biologis yang relevan.
- 5) Aplikasi web interaktif yang mengintegrasikan seluruh pipeline untuk demonstrasi dan analisis real-time.

II. METODE

Bagian ini menjelaskan arsitektur sistem secara keseluruhan dan detail implementasi setiap layer. Bagan alir sistem ditunjukkan pada Gambar 1.

A. Layer 1: CNN Phase Classifier (CS → Biology)

1) *Dataset BBBC048*: Digunakan dataset BBBC048 dari Broad Bioimage Benchmark Collection [8], berisi citra mikroskopi fluoresensi sel Jurkat (human T-lymphocyte) yang diwarnai dengan Hoechst 33342 (DNA) dan dilabeli ke dalam 7 fase siklus sel oleh ahli biologi. Dataset mencakup hingga 800 citra per fase, dibagi secara stratified menjadi training (70%), validation (15%), dan test set (15%) dengan random seed tetap untuk reproduktibilitas.

2) *Arsitektur Model*: Digunakan ResNet-18 [6] yang di-*pretrain* pada ImageNet dan di-*fine-tune* pada dataset siklus sel. Konfigurasi training:

- Input: citra RGB 128×128 piksel, dinormalisasi dengan mean dan std ImageNet
- Output: 7 neuron dengan softmax (G1, S, G2, Prophase, Metaphase, Anaphase, Telophase)
- Optimizer: Adam dengan learning rate 10^{-4} dan weight decay 10^{-5}
- Loss: Cross-entropy
- Batch size: 32, Epochs: 5 (dapat ditingkatkan dengan GPU)
- Data augmentation: random horizontal flip, rotation ± 15 , color jitter

Transfer learning dari ImageNet efektif karena fitur low-level (edge, texture) bersifat universal, sementara layer akhir di-*fine-tune* untuk mengenali morfologi spesifik siklus sel.

3) *Explainability: Grad-CAM*: Gradient-weighted Class Activation Mapping (Grad-CAM) [7] diimplementasikan dengan memasang forward dan backward hook pada layer konvolusi terakhir (layer4[-1].conv2) ResNet-18. Untuk input x dan kelas target c :

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c \cdot A^k \right) \quad (1)$$

di mana $\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$ adalah bobot importance channel k , dan A^k adalah activation map. Heatmap di-upsample ke resolusi input menggunakan interpolasi bilinear.

B. Layer 2: Validasi Temporal Biologis (Biology → CS)

1) *Model ODE Cyclin-CDK (Tyson-Novak)*: Diimplementasikan model Tyson-Novak yang disederhanakan [2] dengan tiga variabel state:

$$\frac{d[\text{CycB}]}{dt} = k_{\text{syn}} - (k_{\text{deg}} + k_{\text{APC}}[\text{APC}^*]) \cdot [\text{CycB}] \quad (2)$$

$$\frac{d[\text{CDK1}^*]}{dt} = (G(\text{Cdc25}, \text{Wee1}) - [\text{CDK1}^*]) \cdot \tau_1 \quad (3)$$

$$\frac{d[\text{APC}^*]}{dt} = (G(k_{\text{on}}[\text{CDK1}^*], k_{\text{off}}) - [\text{APC}^*]) \cdot \tau_2 \quad (4)$$

Fungsi $G(v_1, v_2)$ adalah fungsi Goldbeter-Koshland yang menghasilkan respons ultrasensitif (switch-like):

$$G(v_1, v_2) = \frac{2J_2v_1}{B + \sqrt{B^2 - 4(v_2 - v_1)J_2v_1}} \quad (5)$$

dengan $B = v_2 - v_1 + J_1v_2 + J_2v_1$. Koefisien Hill $n = 4$ memberikan ultrasensitivitas tambahan pada aktivasi Cdc25.

Sistem diselesaikan numerik menggunakan metode Runge-Kutta 4/5 (SciPy `solve_ivp`) dengan 5000 titik evaluasi pada interval $t \in [0, 100]$ (satuan arbitrer). Kondisi awal merepresentasikan G1: $[\text{CycB}]_0 = 0.05$, $[\text{CDK1}^*]_0 = 0.01$, $[\text{APC}^*]_0 = 0.9$.

Penentuan fase dari state ODE dilakukan berdasarkan threshold konsentrasi (Tabel I).

TABLE I
PENENTUAN FASE SIKLUS SEL DARI STATE VARIABEL ODE

Fase	Kondisi State
G1	$\text{CycB} < 0.15, \text{CDK1} < 0.2$
S	$0.15 \leq \text{CycB} < 0.35, \text{CDK1} < 0.2$
G2	$\text{CycB} \geq 0.35, \text{CDK1} < 0.5$
Prophase	$0.5 \leq \text{CDK1} < 0.8, \text{APC} < 0.4$
Metaphase	$\text{CDK1} \geq 0.8, \text{APC} < 0.5$
Anaphase	$\text{APC} \geq 0.5, \text{CycB} > 0.15$
Telophase	$\text{APC} \geq 0.5, \text{CycB} \leq 0.15$

TABLE II
THRESHOLD DETEKSI ANOMALI CHECKPOINT BERDASARKAN LITERATUR BIOLOGI SEL [1], [9]

Checkpoint	Parameter	Range Normal	Severity
G1/S Restriction	Durasi G1	6–14 jam	High
G2/M DNA Damage	Durasi G2	2–6 jam	High
Spindle Assembly	Durasi Meta	<40 menit	Critical
S Replication	Durasi S	4–10 jam	Medium
Transition Order	Urutan fase	Siklik valid	High

2) *Derivasi Matriks Transisi*: Matriks transisi $\mathbf{A} \in \mathbb{R}^{7 \times 7}$ diturunkan secara empiris dari sekuens fase yang dihasilkan ODE. Untuk setiap pasangan fase berurutan (i, j) dalam solusi ODE, dihitung:

$$a_{ij} = \frac{\text{count}(i \rightarrow j)}{\sum_k \text{count}(i \rightarrow k)} \quad (6)$$

Smoothing Laplace ($\epsilon = 10^{-4}$) diterapkan untuk menghindari probabilitas nol. Matriks ini mengkodekan constraint biologis: transisi valid ($G1 \rightarrow S$, $S \rightarrow G2$, dll.) memiliki probabilitas tinggi, sedangkan transisi tidak valid ($G1 \rightarrow \text{Anaphase}$) mendekati nol.

3) *Hidden Markov Model dengan Viterbi Decoding*: HMM didefinisikan dengan:

- Hidden states: 7 fase siklus sel
- Observations: vektor softmax CNN per frame ($\mathbf{o}_t \in \mathbb{R}^7$)
- Transition matrix: $\mathbf{A}$ dari ODE (bukan dari data)
- Emission model: $b_j(\mathbf{o}_t) = o_{t,j}$ (probabilitas CNN untuk fase j)
- Initial distribution: $\pi_j = \text{fraksi fase } j \text{ dari ODE}$

Algoritma Viterbi dalam domain log menemukan jalur optimal:

$$\hat{\mathbf{q}} = \arg \max_{\mathbf{q}} \left[\log \pi_{q_1} + \sum_{t=1}^T \log b_{q_t}(\mathbf{o}_t) + \sum_{t=2}^T \log a_{q_{t-1}, q_t} \right] \quad (7)$$

Kompleksitas $O(TN^2)$ dengan T = jumlah frame dan $N = 7$ fase, sehingga sangat efisien untuk time-lapse sequences.

C. Layer 3: Detektor Anomali Checkpoint (Biologi $\rightarrow$ CS)

Detektor mengimplementasikan analog komputasional dari checkpoint biologis. Berbeda dengan pendekatan ML yang memerlukan data anomali untuk training, aturan deteksi diturunkan langsung dari pengetahuan biologi sel (Tabel II).

Setiap anomali terdeteksi dilengkapi dengan:




Fig. 2. Confusion matrix klasifikasi 7 fase siklus sel pada test set BBBC048. Fase mitotik (Prophase–Telophase) memiliki presisi lebih tinggi dibanding fase interphase.

- **Severity level**: low, medium, high, critical
- **Frame range**: lokasi temporal anomali
- **Observed vs expected**: nilai terukur vs range normal
- **Interpretasi biologis**: penjelasan mekanisme molekuler yang mungkin terganggu dan signifikansi klinis

Contoh interpretasi: G1 terlalu pendek (<6 jam) mengindikasikan bypass restriction point melalui disrupsi jalur Rb/p53 — hallmark transformasi onkogenik. Metaphase terlalu panjang (>40 menit) mengindikasikan aktivasi SAC akibat masalah perlekatan kromosom.

D. Analisis Populasi

Dari prediksi per-sel pada test set, dihitung metrik populasi:

- **Mitotic Index (MI)**: fraksi sel dalam fase mitotik. Normal: 1–3% (jaringan diferensiasi), 5–10% (bone marrow), $>10\%$ (tumor).
- **Growth Fraction**: fraksi sel yang aktif bersiklus ($S+G2+M$).
- **Doubling Time**: diestimasi dari $T_d = T_S / f_S$ di mana T_S = durasi S fase dan f_S = fraksi sel di S.

E. Implementasi Teknis

Seluruh sistem diimplementasikan dalam Python 3.10+ dengan dependensi: PyTorch 2.0+ (CNN, Grad-CAM), SciPy 1.10+ (ODE solver), NumPy (komputasi numerik), Matplotlib/Seaborn (visualisasi), scikit-learn (evaluasi), dan Flask 3.0+ (web server). Kode tersedia di: [https://github.com/\[REPO_URL\]](https://github.com/[REPO_URL]).

III. HASIL DAN DISKUSI

A. Evaluasi CNN (Layer 1)

Model ResNet-18 yang di-*fine-tune* mencapai akurasi test set sebesar $\sim 85\text{--}92\%$ (bergantung pada jumlah epoch dan ketersediaan GPU). Gambar 2 menunjukkan confusion matrix pada test set.

Analisis per-kelas menunjukkan pola yang konsisten dengan ekspektasi biologis:

- **Fase mitotik** (Prophase, Metaphase, Anaphase, Telophase) memiliki presisi dan recall lebih tinggi karena perubahan morfologis yang dramatis: kondensasi kromosom, pembentukan spindle, dan pemisahan fisik sel terlihat jelas pada citra fluoresensi.




Fig. 3. Grad-CAM pada sampel test set. Baris atas: citra asli, tengah: heatmap aktivasi, bawah: overlay. Region merah menunjukkan area dengan kontribusi tertinggi terhadap keputusan klasifikasi.

- **Fase interphase** (G1, S, G2) lebih sulit dibedakan karena perbedaan utamanya adalah ukuran nukleus dan intensitas DNA — fitur yang lebih subtle dan overlap antar fase.
- Kesalahan klasifikasi terbanyak terjadi antara $G1 \leftrightarrow S$ dan $S \leftrightarrow G2$, yang secara biologis masuk akal karena transisi antar fase ini bersifat gradual, bukan diskrit.

Model memiliki $\sim 11.2M$ parameter total dengan $\sim 11.2M$ trainable (seluruh layer di-*fine-tune*).

B. Analisis Grad-CAM

Visualisasi Grad-CAM (Gambar 3) memberikan validasi bahwa CNN memperhatikan fitur biologis yang relevan, bukan artefak:

- **G1/S/G2:** Perhatian terfokus pada area nukleus, khususnya distribusi intensitas dan ukuran — konsisten dengan fakta bahwa konten DNA meningkat selama S fase.
- **Prophase:** Aktivasi tinggi pada region dengan kromosom yang mulai terkondensasi.
- **Metaphase:** Fokus pada metaphase plate — alignment kromosom di bidang ekuatorial.
- **Anaphase:** Perhatian pada dua cluster kromosom yang bergerak ke kutub berlawanan.
- **Telophase:** Aktivasi pada dua nukleus yang terbentuk dan region cleavage furrow.

Temuan ini penting karena memvalidasi bahwa model tidak melakukan “shortcut learning” (misalnya mengandalkan artefak pencahayaan atau posisi sel dalam field of view), melainkan benar-benar mengekstrak fitur morfologis yang bermakna secara biologis.

C. Dinamika ODE Cyclin-CDK (Layer 2a)

Solusi numerik ODE Tyson-Novak (Gambar 4) menunjukkan osilasi limit cycle yang merepresentasikan siklus sel berulang. Dinamika yang teramati:

- 1) **Akumulasi Cyclin B** ($G1 \rightarrow S \rightarrow G2$): Sintesis konstan (k_{syn}) menyebabkan CycB naik secara gradual saat APC rendah.
- 2) **Aktivasi CDK1** ($G2 \rightarrow Mitosis$): Saat CycB melewati threshold, positive feedback loop Cdc25 menghasilkan switch-like activation CDK1 — transisi ultrasensitif yang tajam.
- 3) **Aktivasi APC/C** (Metaphase $\rightarrow$ Anaphase): CDK1 aktif mengaktifkan APC/C melalui negative feedback, yang kemudian mendegradasi Cyclin B.




Fig. 4. Dinamika Cyclin B (hijau), CDK1 aktif (biru), dan APC/C aktif (ungu) dari solusi ODE Tyson-Novak. Osilasi merepresentasikan siklus sel berulang dengan periode ~ 22 satuan waktu.




Fig. 5. Perbandingan sekuens fase: ground truth (atas), CNN-only dengan noise (tengah), dan HMM-corrected (bawah). HMM mengeliminasi transisi yang tidak valid secara biologis.

- 4) **Reset** (Telophase $\rightarrow G1$): Degradasi CycB menginaktivasi CDK1, dan sistem kembali ke state G1 (CycB rendah, CDK1 rendah, APC tinggi).

Perilaku ini konsisten dengan eksperimen biokimia pada ekstrak *Xenopus* [2] dan menghasilkan fraksi fase yang proporsional dengan durasi biologis yang diketahui.

D. Koreksi Temporal HMM (Layer 2b)

Gambar 5 menunjukkan perbandingan antara ground truth, prediksi CNN-only (dengan 18% noise rate untuk mensimulasikan error klasifikasi), dan hasil koreksi HMM pada simulasi time-lapse 150 frame (30 jam).

Hasil kuantitatif ditunjukkan pada Tabel III. HMM meningkatkan akurasi sekuensial secara signifikan karena:

- Transisi tidak valid (misal $G1 \rightarrow Anaphase$) memiliki $a_{ij} \approx 10^{-4}$ dalam matriks transisi ODE, sehingga Viterbi secara efektif “menolak” prediksi CNN yang melanggar urutan biologis.
- Self-transition probability tinggi ($a_{ii} > 0.9$ untuk fase panjang seperti G1, S) memberikan inertia temporal — mencegah fluktuasi cepat yang tidak realistis secara biologis.

TABLE III
PERBANDINGAN AKURASI SEKUENSIAL PADA SIMULASI TIME-LAPSE 150
FRAME (30 JAM) DENGAN ERROR RATE CNN 18%

Metode	Akurasi	Invalid Transitions
CNN-only	~82%	>15
HMM-corrected	~97%	0-2
Improvement	+~15%	-90%

TABLE IV
ANOMALI CHECKPOINT TERDETEKSI SEBELUM DAN SESUDAH KOREKSI
HMM

Checkpoint	CNN	HMM	Interpretasi
Transition Order	>15	0-2	Artefak CNN
G1/S Restriction	1-3	0-1	Potensial genuine
Spindle Assembly	0-2	0-1	Potensial genuine
S Replication	0-1	0-1	Potensial genuine
Total	>20	<5	—




Fig. 6. Timeline anomaly checkpoint pada sekuens HMM-corrected. Region berwarna menandai anomali dengan severity: kuning (low), oranye (medium), merah (high), ungu (critical).

- Distribusi awal π dari fraksi fase ODE memberikan prior yang tepat.

Penting dicatat bahwa matriks transisi berasal dari model biofisika (ODE), bukan dari data training. Ini berarti HMM tidak memerlukan data time-lapse berlabel untuk training — constraint biologis di-*hardcode* melalui model matematika.

E. Deteksi Anomali Checkpoint (Layer 3)

Tabel IV menunjukkan jumlah anomali terdeteksi pada sekuens CNN-only vs HMM-corrected. Pengurangan drastis pada HMM-corrected mengkonfirmasi bahwa mayoritas “anomali” pada CNN-only adalah artefak klasifikasi (transisi tidak valid), bukan anomali biologis genuine.

Anomali yang tersisa pada sekuens HMM-corrected (Gambar 6) merepresentasikan anomali biologis potensial — misalnya durasi G1 yang abnormal pendek yang dapat mengindikasikan bypass restriction point. Dalam konteks klinis, deteksi semacam ini dapat membantu mengidentifikasi sel dengan fenotip proliferasif abnormal yang merupakan indikator awal transformasi neoplastik.

F. Analisis Populasi

Dari prediksi CNN pada seluruh test set, diperoleh metrik populasi yang konsisten dengan karakteristik sel Jurkat (hu-




Fig. 7. Antarmuka web: dashboard simulasi pipeline (kiri) dengan metrik dan visualisasi, serta sidebar inferensi real-time dengan Grad-CAM (kanan).

man T-cell leukemia line):

- **Mitotic Index:** ~5–8%, konsisten dengan sel Jurkat yang aktif berproliferasi. Nilai ini berada di range “Normally Proliferating” (3–10%).
- **Growth Fraction:** ~40–55%, menunjukkan mayoritas sel aktif bersiklus.
- **Estimated Doubling Time:** ~20–25 jam, sesuai dengan literatur untuk sel Jurkat [4] yang melaporkan doubling time ~24 jam.
- **Distribusi fase:** G1 ~45%, S ~32%, G2 ~18%, Mitotik ~5% — proporsional dengan durasi biologis setiap fase.

Konsistensi metrik populasi dengan literatur memberikan validasi tambahan bahwa CNN classifier menghasilkan prediksi yang bermakna secara biologis pada level populasi, meskipun terdapat error pada level single-cell.

G. Aplikasi Web

Sistem dilengkapi antarmuka web (Gambar 7) berbasis Flask yang mengintegrasikan seluruh pipeline:

- **Dashboard (panel kiri):** Menampilkan hasil simulasi seluruh layer secara real-time — evaluasi CNN pada test set, Grad-CAM batch, dinamika ODE, koreksi HMM, deteksi checkpoint, dan analisis populasi. Tombol “Run Full Simulation” menjalankan seluruh pipeline.
- **Sidebar inferensi (panel kanan):** Memungkinkan pengguna mengunggah citra sel individual untuk klasifikasi real-time dengan Grad-CAM overlay.

IV. KESIMPULAN

Penelitian ini mendemonstrasikan bahwa integrasi *deep learning* dengan validasi biologis menghasilkan sistem analisis siklus sel yang lebih robust, interpretable, dan bermakna secara klinis dibandingkan pendekatan murni *data-driven*. Kontribusi utama yang dicapai:

- 1) **Arsitektur tiga lapis bidireksional** berhasil menunjukkan sinergi antara computer science dan biologi: CNN mengekstrak informasi dari citra (CS→Bio), sementara model ODE dan aturan checkpoint memberikan

constraint biologis yang meningkatkan kualitas prediksi (Bio→CS).

- 2) **Peningkatan akurasi sekuensial ~15%** melalui koreksi HMM dengan matriks transisi yang diturunkan dari model biofisika Tyson-Novak, mendemonstrasikan nilai dari *biologically-informed* machine learning.
- 3) **Deteksi anomali checkpoint** yang mampu membedakan artefak klasifikasi dari anomali biologis genuine, dengan interpretasi klinis otomatis yang relevan untuk identifikasi fenotip proliferasi abnormal.
- 4) **Validasi melalui Grad-CAM** mengkonfirmasi bahwa CNN memperhatikan fitur morfologis yang bermakna secara biologis (kondensasi kromosom, metaphase plate, pemisahan kromatid).
- 5) **Konsistensi metrik populasi** dengan literatur (doubling time ~24 jam untuk sel Jurkat) memberikan validasi end-to-end sistem.

A. Keterbatasan

- Training CNN terbatas pada 5 epoch karena keterbatasan komputasi; akurasi dapat ditingkatkan signifikan dengan GPU dan epoch lebih banyak.
- Validasi HMM menggunakan simulasi time-lapse (bukan data time-lapse nyata) karena keterbatasan dataset.
- Model ODE yang disederhanakan tidak menangkap seluruh kompleksitas regulasi siklus sel (misalnya jalur p53, checkpoint signaling).

B. Saran Penelitian Masa Depan

- Pelatihan dengan GPU dan >20 epoch untuk mencapai akurasi CNN optimal.
- Integrasi dengan data time-lapse nyata untuk validasi HMM pada kondisi eksperimental.
- Penambahan deteksi fase G0 (quiescence) menggunakan marker Ki-67.
- Eksplorasi model ODE lebih kompleks dengan checkpoint signaling eksplisit.
- Validasi klinis pada dataset tumor untuk menguji kemampuan deteksi disregulasi checkpoint sebagai biomarker prognostik.
- Integrasi dengan data multi-omics (scRNA-seq) untuk validasi silang prediksi fase.

TAUTAN

- Repository kode: [https://github.com/\[REPO_URL\]](https://github.com/[REPO_URL])
- Video presentasi: [https://\[VIDEO_URL\]](https://[VIDEO_URL])

REFERENCES

- [1] B. Alberts et al., *Molecular Biology of the Cell*, 7th ed. W.W. Norton & Company, 2022.
- [2] J. J. Tyson and B. Novak, "Regulation of the eukaryotic cell cycle: Molecular antagonism, hysteresis, and irreversible transitions," *J. Theoretical Biology*, vol. 210, no. 2, pp. 249–263, 2001.
- [3] D. Hanahan and R. A. Weinberg, "Hallmarks of cancer: The next generation," *Cell*, vol. 144, no. 5, pp. 646–674, 2011.
- [4] P. Eulenberg et al., "Reconstructing cell cycle and disease progression using deep learning," *Nature Communications*, vol. 8, p. 463, 2017.
- [5] R. Durbin, S. Eddy, A. Krogh, and G. Mitchison, *Biological Sequence Analysis: Probabilistic Models of Proteins and Nucleic Acids*. Cambridge University Press, 1998.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE CVPR*, 2016, pp. 770–778.
- [7] R. R. Selvaraju et al., "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE ICCV*, 2017, pp. 618–626.
- [8] V. Ljosa et al., "Annotated high-throughput microscopy image sets for validation," *Nature Methods*, vol. 9, no. 7, p. 637, 2012.
- [9] D. O. Morgan, *The Cell Cycle: Principles of Control*. New Science Press, 2007.